

EM algorithm

on mixture of Gaussians

인공지능융합학과

2021123173

송 우 석

1. Introduction

1.1 EM algorithm

Expectation-maximization 알고리즘은 관측되지 않는 잠재변수에 의존하는 확률 모델에서 "maximum likelihood"를 갖는 모수의 추정값을 찾는 반복적인 알고리즘이다. EM 알고리즘은 모수에 관한 추정값으로 'log likelihood'의 기댓값을 계산하는 (E) 단계와 이 기댓값을 최대화하는 모수 추정값들을 구하는 (M) 단계를 번갈아가면서 적용한다. (M) 단계에서 계산한 변수값은 다음 (E) 단계의 추정값으로 쓰인다. [1]

• likelihood function : $Z = (X, Y)$ 가 주어졌을 때 Θ 에 대한 cost function.

$$L(\Theta | Z) = L(\Theta | X, Y) = p(X, Y | \Theta)$$
$$Q(\Theta, \Theta^{(i)}) = E[\log p(X, Y | \Theta) | X, \Theta^{(i)}] \Rightarrow \text{log-likelihood.}$$

: expected value of the complete-data

(E-step)

$$E[\log p(X, Y | \Theta) | X, \Theta^{(i)}] = \int \log p(X, Y | \Theta) p(Y | X, \Theta^{(i)}) dY$$

(M-step)

$$\Theta^{(i)} = \arg\max_{\Theta} Q(\Theta, \Theta^{(i-1)})$$

1.2 Mixture of Gaussian

1.2.1 Gaussian distribution

정규분포는 2개의 매개 변수 평균과 표준편차에 대해 모양이 결정되는 연속 확률 분포이다.

Gaussian 분포. ($\theta_j = \mu_j, \Sigma_j$)

$$\begin{aligned} p_j(x|\theta_j) &= p_j(x|\mu_j, \Sigma_j) \\ &= \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma_j|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(x-\mu_j)^T \Sigma_j^{-1} (x-\mu_j)\right] \end{aligned}$$

1.2.2 Mixture model : linear combination of m densities

$$p(x|\Theta) = \sum_{j=1}^m \alpha_j p_j(x|\theta_j) \quad \dots\dots ②$$

$$\begin{aligned} \text{where } \Theta &= (\alpha_1, \dots, \alpha_m, \theta_1, \dots, \theta_m) \\ (\text{s.t. } \alpha_j \geq 0, \sum_j \alpha_j &= 1) \end{aligned}$$

• The loglikelihood function of Θ

$$\log L(\Theta|X, Y) = \log p(X, Y|\Theta) \quad ①$$

$$= \log p(X|Y, \Theta) p(Y|\Theta)$$


$$= \sum_{i=1}^N \log (p(x_i|y_i, \theta_{y_i}) p(y_i|\theta_{y_i}))$$

$$= \sum_{i=1}^N \log (\alpha_{y_i} p_{y_i}(x_i|\theta_{y_i}))$$

2. Experiment Method

2.1 Mixture of Gaussian(MoG) -2차원

밑의 그림과 같이 평균과 분산을 입력해 주면 여러개의 가우시안 분포가 생성되고 , 생성된 데이터를 모두 모아서 Mixture of Gaussian을 만들었다. 그림은 different spherical covariance를 가지는 5개의 가우시안 분포의 mixture 이다.



- MoG를 생성할 때 다음과 같이 5가지 분산 형태를 사용해서 실험을 했다.

Case1. Same spherical covariance

Case2. Different spherical covariance

Case3. Different diagonal covariance

Case4. Arbitrary same covariance

Case5. Arbitrary covariance

- 각각의 case 마다 가우시안 분포를 5개, 7개로 설정해서 실험을 했다.
- 총 10가지(5가지 variance에 대해서 5개 섞었을 때, 7개 분포 섞었을 때 - $> 5 \times 2 = 10$) 분포의 결과를 명시했습니다. 7개의 분포를 섞을 때는 분포들끼리 겹치게 설정을 하기도 했습니다.

2.2 EM algorithm on MoG (코드는 ipynb 파일로 따로 첨부하겠습니다)

2.2.1 Expectation step

(E-step)

$\Theta^{(0)}$: initial parameters = $(\alpha_1^{(0)} \dots \alpha_m^{(0)}, \theta_1^{(0)} \dots \theta_m^{(0)})$

$$\textcircled{1} \quad p(y_i | x_i, \Theta^{(0)}) = \frac{p(y_i, x_i | \Theta^{(0)})}{p(x_i | \Theta^{(0)})} = \frac{\alpha_{y_i}^{(0)} p_{y_i}(x_i | \theta_{y_i}^{(0)})}{p(x_i | \Theta^{(0)})}$$

$$\textcircled{2} \quad \frac{\alpha_{y_i}^{(0)} p_{y_i}(x_i | \theta_{y_i}^{(0)})}{\sum_{j=1}^m \alpha_j^{(0)} p_j(x_i | \theta_j^{(0)})} \Rightarrow p(Y | X, \Theta^{(0)}) = \prod_{i=1}^n p(y_i | x_i, \Theta^{(0)})$$

$$Q(\Theta, \Theta^{(0)}) = \sum_y \log p(X, y | \Theta) p(y | X, \Theta^{(0)})$$

||

$$\log p(X, Y | \Theta)$$

||

$$\sum_{i=1}^n \log(\alpha_{y_i} p_{y_i}(x_i | \theta_{y_i})) = \sum_{i=1}^n \sum_{j=1}^m \log(\alpha_j p_j(x_i | \theta_j))$$

$$Q = \sum_{j=1}^m \sum_{i=1}^n \left[\log(\alpha_j) p(j | x_i, \Theta^{(0)}) + \log(p_j(x_i | \theta_j)) p(j | x_i, \Theta^{(0)}) \right]$$

2.2.2 Maximization step

2.2.2.1 알파(mixing parameters) 업데이트

$$\begin{aligned} \max_{\alpha} Q \quad & (\text{s.t } \alpha_j \geq 0, \sum_j \alpha_j = 1) \\ \Rightarrow \frac{\partial(Q + \lambda(\sum_j \alpha_j - 1))}{\partial \alpha_j} &= \frac{\partial Q}{\partial \alpha_j} + \lambda = 0 \Rightarrow \frac{\partial Q}{\partial \alpha_j} = -\lambda \\ \underbrace{\frac{1}{\alpha_j} \cdot \frac{\sum_{i=1}^n p(j|x_i, \theta^{(n)})}{b_j}}_{=} &= -\lambda \Rightarrow \alpha_j = \frac{b_j}{-\lambda} \left(\sum_j \alpha_j = 1 \right. \\ &\parallel \\ &- \frac{\sum b_j}{\lambda} = 1 \\ &\therefore -\lambda = \underline{\sum_j b_j} \\ \alpha_j &= \frac{b_j}{\sum_j b_j} \\ // \\ \frac{\sum_{i=1}^n p(j|x_i, \theta^{(n)})}{\sum_i \sum_j \underbrace{p(j|x_i, \theta^{(n)})}_1} &= \frac{\sum_{j=1}^J p(j|x_i, \theta^{(n)})}{N} \end{aligned}$$

2.2.2.2 평균 업데이트

ii) θ_j 찾기. - μ_j

Gaussian 분포. $(\theta_j = \mu_j, \Sigma_j)$

$$p_j(x|\theta_j) = p_j(x|\mu_j, \Sigma_j) \\ = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma_j|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(x-\mu_j)^T \Sigma_j^{-1} (x-\mu_j)\right]$$

$$\frac{\partial Q}{\partial \mu_j} = \frac{\partial \left[\sim + \sum_i \sum_j \log(p_j(x_i|\theta_j)) p(j|x_i, \theta^{(0)}) \right]}{\partial \mu_j} = 0$$

$$= \frac{\partial \left[\sum_i \sum_j \left[-\frac{1}{2} \log 2\pi - \frac{1}{2} \log |\Sigma_j| - \frac{1}{2} (x_i - \mu_j)^T \Sigma_j^{-1} (x_i - \mu_j) \right] p_{ji} \right]}{\partial \mu_j}$$

$$= -\frac{1}{2} \sum_i \sum_j \Sigma_j^{-1} (x_i - \mu_j) p_{ji} \quad \therefore \hat{\mu}_j = \frac{\sum_i x_i p_{ji}}{\sum_i p_{ji}}$$

2.2.2.3 분산 업데이트

iii) Σ_j 찾기.

$$\frac{\partial Q}{\partial \Sigma_j} = \sum_i \left(-\frac{1}{2} \Sigma_j^{-1} + \frac{1}{2} \Sigma_j^{-1} (x_i - \mu_j) (x_i - \mu_j)^T \Sigma_j^{-1} \right) p_{ji} = 0$$

각항 양쪽에 Σ_j 곱해.

$$\sum_i \left(-\Sigma_j + (x_i - \mu_j) (x_i - \mu_j)^T \right) p_{ji} = 0$$

$$\Rightarrow \sum_i p_{ji} \Sigma_j = \sum_i (x_i - \mu_j) (x_i - \mu_j)^T p_{ji}$$

$$\Sigma_j = \frac{\sum_i p_{ji} (x_i - \mu_j) (x_i - \mu_j)^T}{\sum_i p_{ji}}$$

2.2.3 Log-likelihood

Log-likelihood를 최대화 시키는 parameter을 찾기위해 E-step과 M-step의 iteration을 반복했습니다.

iteration 마다 계산된 Log-likelihood를 그래프로 나타내었고,

Epsilon= $1e-5$ 라는 threshold를 설정하여 iteration을 마친 후 최대화된 log-likelihood를 적었습니다.

2.2.4 (Optimized) Parameters

원래 분포의 평균,분산, mixing parameter(알파) 와 EM 알고리즘 적용 후의 평균,분산, mixing parameter를 적었습니다. (반올림해서 적어놓았습니다.)

2.2.5 Clustering 정확도

새로 구한 parameter들과 E-step에서 구한 확률로 클러스터링을 하였고, (그 결과를) 색깔을 다르게 하여 시각화 했고, 클러스터링된 가우시안 분포를 잘 보여주는 타원을 그렸습니다.


또한 원래 분포의 라벨(클러스터 라벨)과 비교하여 클러스터링 정확도를 계산했습니다.

3. Result

3.1 5개의 Gaussian mixture

- Case1. Same spherical covariance

- 원래분포 vs 새로 구한 parameter와 확률로 클러스터링 한 분포




- Clustering 정확도: 100%
- 원래 평균,분산,mixing parameter vs 새로 구한 평균,분산,mixing parameter

원래분포	After EM
mean	mean
$\begin{bmatrix} [-20 & 20] \\ [20 & 20] \\ [20 & -20] \\ [60 & 1] \\ [80 & 40] \end{bmatrix}$	$\begin{bmatrix} [20.1 & 19.8] \\ [78.6 & 40.8] \\ [19.9 & -19.2] \\ [-19. & 19.1] \\ [60.5 & 0.5] \end{bmatrix}$
coVariance	coVariance
$\begin{bmatrix} [[50 & 0] \\ [0 & 50]] \\ [[50 & 0] \\ [0 & 50]] \\ [[50 & 0] \\ [0 & 50]] \\ [[50 & 0] \\ [0 & 50]] \\ [[50 & 0] \\ [0 & 50]] \end{bmatrix}$	$\begin{bmatrix} [[37.9 & -10.6] \\ [-10.6 & 49.4]] \\ [[45.5 & 9.9] \\ [9.9 & 20.1]] \\ [[46.9 & 3.8] \\ [3.8 & 55.4]] \\ [[34.4 & 13.5] \\ [13.5 & 58.2]] \\ [[47.8 & -9.1] \\ [-9.1 & 60.1]] \end{bmatrix}$
alpha	alpha
$[0.2, 0.2, 0.2, 0.2, 0.2]$	$[0.2 \ 0.2 \ 0.2 \ 0.2 \ 0.2]$


- Loglikelihood 변화 (iteration 31번)

Maximized loglikelihood = -1229.114379



- Case2. Different spherical covariance

- 원래분포 vs 새로 구한 parameter와 확률로 클러스터링 한 분포




- Clustering 정확도: 100%

■ 원래 평균과 분산 vs 새로구한 평균과 분산

원래분포	After EM
mean	mean
$\begin{bmatrix} -20 & 20 \\ 20 & 20 \\ 20 & -20 \\ 60 & 1 \\ -40 & -20 \end{bmatrix}$	$\begin{bmatrix} -39.1 & -21.1 \\ 18.2 & 21.5 \\ 59.4 & 1.7 \\ -19.9 & 19.7 \\ 20.1 & -22.3 \end{bmatrix}$
coVariance	coVariance
$\begin{bmatrix} 20 & 0 \\ 0 & 20 \end{bmatrix}$	$\begin{bmatrix} 64.3 & 3.5 \\ 3.5 & 58.2 \end{bmatrix}$
$\begin{bmatrix} 30 & 0 \\ 0 & 30 \end{bmatrix}$	$\begin{bmatrix} 28.3 & -1.4 \\ -1.4 & 24.5 \end{bmatrix}$
$\begin{bmatrix} 40 & 0 \\ 0 & 40 \end{bmatrix}$	$\begin{bmatrix} 57.6 & -9. \\ -9. & 43.2 \end{bmatrix}$
$\begin{bmatrix} 50 & 0 \\ 0 & 50 \end{bmatrix}$	$\begin{bmatrix} 20.2 & -10.5 \\ -10.5 & 26.5 \end{bmatrix}$
$\begin{bmatrix} 60 & 0 \\ 0 & 60 \end{bmatrix}$	$\begin{bmatrix} 39.1 & 4.6 \\ 4.6 & 37.9 \end{bmatrix}$
alpha	alpha
$[0.09 \ 0.09 \ 0.18 \ 0.27 \ 0.36]$	$[0.4 \ 0.1 \ 0.3 \ 0.1 \ 0.2]$


■ Loglikelihood 변화 (iteration 31번)

Maximized loglikelihood = -1781.499086



● Case3. Different diagonal covariance

■ 원래분포 vs 새로 구한 parameter와 확률로 클러스터링 한 분포



■ Clustering 정확도: 98.7%

■ 원래 평균,분산,mixing parameter vs 새로 구한 평균,분산,mixing parameter

원래분포

mean

```
[[ 0 10]
 [ 20 8]
 [ 20 -20]
 [ 40 1]
 [-10 -20]]
```

coVariance

```
[[[100 0]
 [ 0 1]]
```

```
[[ 5 0]
 [ 0 80]]
```

```
[[120 0]
 [ 0 2]]
```

```
[[100 0]
 [ 0 5]]
```

```
[[ 10 0]
 [ 0 70]]]
```

alpha

```
[0.2 0.2 0.2 0.2 0.2]
```

After EM

mean

```
[[ 19.4 -19.9]
 [ 20.3 5.1]
 [-2.7 10. ]
 [ 43.6 0.9]
 [-9.7 -17.6]]
```

coVariance

```
[[[ 88.3 2.6]
 [ 2.6 1.3]]
```

```
[[ 3.9 -1.8]
 [-1.8 56. ]]
```

```
[[107.4 -0.7]
 [-0.7 0.7]]
```

```
[[ 52.3 0.7]
 [ 0.7 4.4]]
```


```
[[ 13.5 2.7]
 [ 2.7 70.2]]]
```

alpha

```
[0.2 0.2 0.2 0.2 0.2]
```


- Loglikelihood 변화 (iteration 43번)

Maximized loglikelihood = -1062.542528



- Case4. Arbitrary same covariance

- 원래분포 vs 새로 구한 parameter와 확률로 클러스터링 한 분포




- Clustering 정확도: 98.7%

- 원래 평균,분산,mixing parameter vs 새로 구한 평균,분산,mixing parameter

원래분포	After EM
mean	mean
[[0 0]	[[-19.5 -1.9]
[20 20]	[21.4 1.9]
[20 -20]	[18.5 -20.2]
[20 1]	[-0.6 -0.9]
[-20 -2]]	[19.3 19.4]]
coVariance	coVariance
[[[10 10]	[[[16.1 8.5]
[30 10]]	[8.5 10.6]]
[[10 10]	[[28.4 9.7]
[30 10]]	[9.7 8.7]]
[[10 10]	[[32.8 10.9]
[30 10]]	[10.9 11.6]]
[[10 10]	[[40.7 8.9]
[30 10]]	[8.9 9.4]]
[[10 10]	[[20.4 6.9]
[30 10]]]	[6.9 8.9]]]
alpha	alpha
[0.2 0.2 0.2 0.2 0.2]	[0.2 0.2 0.2 0.2 0.2]


- Loglikelihood 변화 (iteration 57번)

Maximized loglikelihood = -1047.057826



- Case5. Arbitrary covariance

- 원래분포 vs 새로 구한 parameter와 확률로 클러스터링 한 분포




- Clustering 정확도: 97%

- 원래 평균,분산,mixing parameter vs 새로 구한 평균,분산,mixing parameter

원래분포	After EM
mean	mean
[[0 0]	[[20.6 0.7]
[20 20]	[1.1 -1.3]
[20 -20]	[20.6 -19.9]
[20 1]	[18.2 19.]
[-20 -2]]	[-19.9 -2.8]]
coVariance	coVariance
[[[16 10]	[[[31. 13.]
[10 100]]	[13. 11.]]
[[50 7]	[[32.4 -2.5]
[1 7]]	[-2.5 150.7]]
[[10 4]	[[30.1 -1.2]
[70 6]]	[-1.2 2.3]]
[[10 10]	[[88. 2.3]
[30 10]]	[2.3 5.1]]
[[10 70]	[[14.8 11.2]
[20 26]]]	[11.2 83.4]]]
alpha	alpha
[0.11 0.11 0.11 0.3 0.37]	[0.3 0.1 0.1 0.1 0.4]

- Loglikelihood 변화 (iteration 54번)


Maximized loglikelihood = -1994.509828



3.2 7개의 Gaussian mixture

- Case1. Same spherical covariance

- 원래분포 vs 새로 구한 parameter와 확률로 클러스터링 한 분포




- Clustering 정확도: 76.7%

- 원래 평균,분산,mixing parameter vs 새로 구한 평균,분산,mixing parameter

원래분포	After EM
mean	mean
[[-20 20]	[[-1.5 -39.6]
[20 20]	[5.1 -39.5]
[20 -20]	[-19. 19.5]
[60 1]	[19. 19.8]
[80 40]	[59.1 2.9]
[0 -40]	[79.2 0.2]
[80 -40]]	[20.8 -20.4]]
coVariance	coVariance
[[[50 0]	[[[15.6 -19.2]
[0 50]]	[-19.2 52.7]]
[[[50 0]	[[[62.1 19.3]
[0 50]]	[19.3 22.5]]
[[[50 0]	[[[52.7 8.3]
[0 50]]	[8.3 47.1]]
[[[50 0]	[[[37.2 7.6]
[0 50]]	[7.6 62.7]]
[[[50 0]	[[[27.3 -8.]
[0 50]]	[-8. 35.2]]
[[[50 0]	[[[42.7 8.9]
[0 50]]	[8.9 1584.2]]
[[[50 0]	[[[38.9 -5.5]
[0 50]]]	[-5.5 26.7]]]
alpha	alpha
[0.14 0.14 0.14 0.14 0.14 0.14 0.14]	[0.1 0.1 0.1 0.1 0.1 0.3 0.1]


- Loglikelihood 변화 (iteration 92번)

Maximized loglikelihood = -1842.365787



- Case2. Different spherical covariance

- 원래분포 vs 새로 구한 parameter와 확률로 클러스터링 한 분포



- Clustering 정확도: 99.7%

- 원래 평균과 분산 vs 새로구한 평균과 분산

원래분포

mean

```
[[ 0  0]
 [ 60 40]
 [-20 20]
 [ 20 20]
 [ 20 -20]
 [ 60  1]
 [-40 -20]]
```

coVariance

```
[[[ 5  0]
 [ 0  5]]
```

```
[[10  0]
 [ 0 10]]
```

```
[[20  0]
 [ 0 20]]
```

```
[[30  0]
 [ 0 30]]
```

```
[[40  0]
 [ 0 40]]
```

```
[[50  0]
 [ 0 50]]
```

```
[[60  0]
 [ 0 60]]]
```

alpha

```
[0.06 0.06 0.12 0.18 0.24 0.18 0.18]
```

After EM

mean

```
[[ 20.6 20.4]
 [ 58.  40.2]
 [-39.6 -20.7]
 [ 20.1 -20.9]
 [ 60.2   2.5]
 [-20.1 18.7]
 [-0.3  0.6]]
```

coVariance

```
[[[33.  -7.6]
 [-7.6 19.1]]
```

```
[[42.1 -3.7]
 [-3.7 16.6]]
```

```
[[38.9  5. ]
 [  5.  57. ]]
```

```
[[25.8  7.7]
 [  7.7 38.3]]
```

```
[[45.6 -3.8]
 [-3.8 52.6]]
```

```
[[26.4  1.9]
 [  1.9 19.1]]
```


```
[[ 3.3  0.1]
 [  0.1  4.7]]]
```

alpha

```
[0.2 0.1 0.2 0.2 0.2 0.1 0.1]
```


- Loglikelihood 변화 (iteration 31번)

Maximized loglikelihood = **-2737.723874**



- Case3. Different diagonal covariance

- 원래분포 vs 새로 구한 parameter와 확률로 클러스터링 한 분포




- Clustering 정확도: 80%

■ 원래 평균,분산,mixing parameter vs 새로 구한 평균,분산,mixing parameter

원래분포	After EM
mean	mean
[[60 20]	[[21. 7.]
[70 -20]	[-10.4 -19.5]
[0 10]	[55.6 -9.2]
[20 8]	[-12.6 9.7]
[20 -20]	[60.3 21.4]
[40 1]	[6.2 10.5]
[-10 -20]]	[17.9 -19.9]]
coVariance	coVariance
[[[4 0]	[[[5.6 -0.9]
[0 50]]	[-0.9 57.5]]
[[1 0]	[[12. 5.3]
[0 20]]	[5.3 108.9]]
[[100 0]	[[302. -163.1]
[0 1]]	[-163.1 120.7]]
[[5 0]	[[26.5 -2.2]
[0 80]]	[-2.2 0.9]]
[[120 0]	[[3.6 1.1]
[0 2]]	[1.1 36.6]]
[[100 0]	[[62.4 -1.9]
[0 5]]	[-1.9 0.9]]
[[10 0]	[[89.9 -1.2]
[0 70]]]	[-1.2 2.]]]
alpha	alpha
[0.14 0.14 0.14 0.14 0.14 0.14 0.14]	[0.1 0.1 0.3 0. 0.1 0.1 0.1]


■ Loglikelihood 변화 (iteration 86번)

Maximized loglikelihood = -1635.832905



- Case4. Arbitrary same covariance

- 원래분포 vs 새로 구한 parameter와 확률로 클러스터링 한 분포




- Clustering 정확도: 88.1%

- 원래 평균,분산,mixing parameter vs 새로 구한 평균,분산,mixing parameter

원래분포	After EM
mean	mean
[[-20 20]	[[-19.7 -20.3]
[-20 -20]	[21.1 20.9]
[0 0]	[17.2 -21.2]
[20 20]	[-10.6 -1.1]
[20 -20]	[-20.3 19.]
[20 1]	[2.9 3.]
[-20 -2]]	[19.3 0.9]]
coVariance	coVariance
[[[10 10]	[[[22.5 11.1]
[30 10]]	[11.1 15.3]]
[[10 10]	[[42.2 8.8]
[30 10]]	[8.8 5.6]]
[[10 10]	[[27.8 10.5]
[30 10]]	[10.5 8.7]]
[[10 10]	[[105.5 16.3]
[30 10]]	[16.3 9.7]]
[[10 10]	[[48.1 16.5]
[30 10]]	[16.5 8.5]]
[[10 10]	[[41.4 29.9]
[30 10]]	[29.9 21.9]]
[[10 10]	[[25.2 10.1]
[30 10]]	[10.1 8.5]]]
alpha	alpha
[0.14 0.14 0.14 0.14 0.14 0.14 0.14]	[0.1 0.1 0.1 0.3 0.1 0. 0.1]

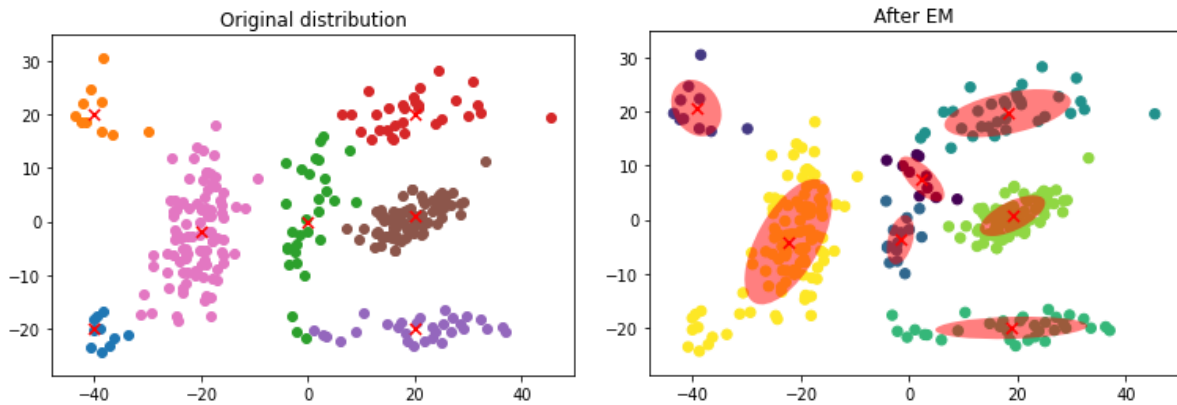
■ Loglikelihood 변화 (iteration 35번)

Maximized loglikelihood = -1532.796690



- Case5. Arbitrary covariance

■ 원래분포 vs 새로 구한 parameter와 확률로 클러스터링 한 분포




■ Clustering 정확도: 91%

■ 원래 평균,분산,mixing parameter vs 새로 구한 평균,분산,mixing parameter

<pre> 원래분포 mean [[-40 -20] [-40 20] [0 0] [20 20] [20 -20] [20 1] [-20 -2]] coVariance [[[3 4] [-10 11]] [[-1 19] [20 9]] [[16 10] [10 100]] [[50 7] [1 7]] [[10 4] [70 6]] [[10 10] [30 10]] [[10 70] [20 26]]] alpha [0.03 0.03 0.1 0.1 0.1 0.28 0.34] </pre>	<pre> After EM mean [[-22.3 -4.1] [-1.6 -3.7] [18.9 -20.] [18.2 19.7] [2.3 7.5] [19.1 0.7] [-39.4 20.7]] coVariance [[[41.7 36.5] [36.5 86.1]] [[4.1 2.6] [2.6 13.3]] [[126. 3.4] [3.4 2.7]] [[87.4 16.] [16. 12.6]] [[11.2 -7.9] [-7.9 11.2]] [[23.3 9.2] [9.2 9.1]] [[13.8 -3.5] [-3.5 17.5]]] alpha [0.4 0. 0.1 0.1 0. 0.3 0.] </pre>
---	--

■ Loglikelihood 변화 (iteration 110번)

Maximized loglikelihood = -2180.551871



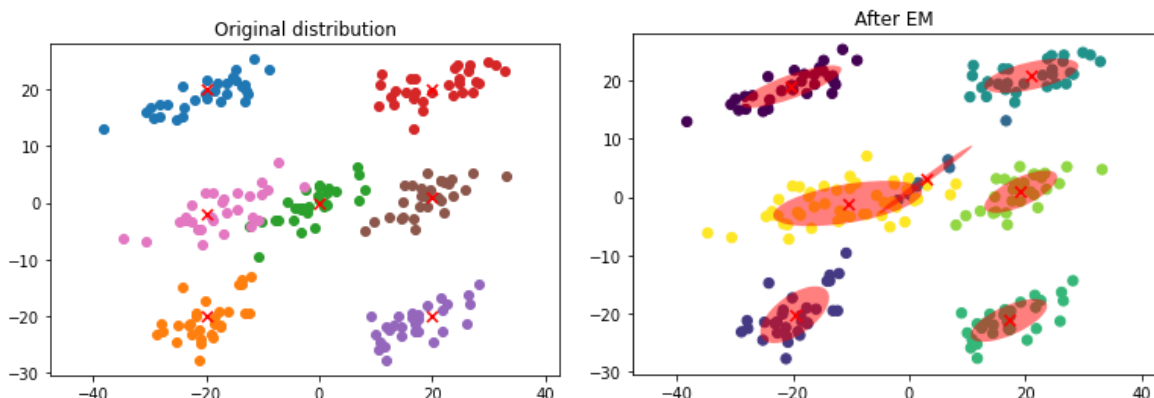
4. Discussion

4.1 Result 부분에 명시한 부분 말고도 다양한 초기값, 다양한 분포 수에 대해서도 실험을 해보았다. Mixing parameter, 평균, 분산, 즉 몇 개의 파라미터 만으로 클러스터를 특정지을 수 있다는 장점을 잘 확인했다. 가우시안 분포끼리 서로 겹치지 않을 때 클러스터링 정확도가 100%에 가깝게 매우 높았다.

4.2 하지만, EM 알고리즘은 Likelihood의 global maximization을 찾는게 아니라 local한 maximization을 하는 것이라서 초기값에 따라서 지역해에 빠질 수가 있다는 것을 확인했다. 따라서 초기값에 따라서 클러스터링을 잘 하지 못하는 경우를 확인했고, 그런 분포들은 다른 초기값을 주고 iteration을 돌리면 클러스터링이 잘 되고 loglikelihood도 더 크게 나왔다.

4.3 또한 데이터 분포가 서로 겹치게 생기는 부분이 있으면 밑의 그림과 같이 클러스터링을 일부 잘 못하는 경우가 발생한다.

- Ex) 원래 분포에서 분홍색, 초록색은 다른 가우시안 분포로부터 나온 데이터인데, EM알고리즘을 적용한 노란색 부분처럼 하나의 가우시안 분포로 클러스터링된다.
- 초기값을 적절하게 주고 다시 iteration을 돌리면 클러스터링이 잘 된다.



4.4 분포가 여러 개일수록, 계산량(소요시간)이 많다는 것을 확인했다.
(computationally expensive)

4.5 나는 원래 분포가 몇 개의 (클러스터)가우시안 분포로 이루어져 있는지를 알려주고 클러스터링을 시켰지만, ex) “이렇게 생긴 분포를 7 개의 가우시안 분포로 클러스터링해 !” 원래 분포의 클러스터 개수를 미리 알지 못 한다면 육안으로 클러스터 개수를 추정하기 힘들다는 단점이 있다고 느꼈다.

5. Appendix

코드 첨부는 ipynb 파일로 따로 첨부하겠습니다. 코드에 주석처리로 부가 설명을 해 놓았습니다.

6. Reference

[1] 위키피디아

https://ko.wikipedia.org/wiki/%EA%B8%B0%EB%8C%93%EA%B0%92_%EC%B5%9C%EB%8C%80%ED%99%94_%EC%95%8C%EA%B3%A0%EB%A6%AC%EC%A6%98